

Document RAG API - Amazon Bedrock障害対応Runbook

1. 目的

本Runbookは、Document RAG APIからAmazon Bedrockを利用する際に発生する障害の確認および切り分け手順を定める。

- /chat が503を返す
- Embedding生成に失敗する
- Claudeによる回答生成に失敗する
- Bedrock呼び出し時にAccessDeniedが発生する
- Model IDまたはInference Profileの設定に問題がある
- 利用できないモデルを指定している

2. Document RAG APIにおけるBedrockの役割

Embedding生成

Amazon Titan Text Embeddings V2を利用する。テキストをVectorへ変換し、S3 Vectorsへの保存および類似検索に利用する。Embedding生成ではBedrock Runtimeの InvokeModel APIを使用する。

回答生成

Claude Sonnet 4.6を利用する。S3 Vectorsから取得した参考文献とユーザーの質問を入力としてRAG回答を生成する。回答生成ではBedrock Runtimeの Converse APIを使用する。

Embedding生成と回答生成は異なるモデルおよび処理であるため、Bedrock障害時はどちらで失敗しているかを切り分ける。

3. /chat の処理フロー

1. ユーザーから質問を受信する
2. Titan Text Embeddings V2で質問のEmbeddingを生成する
3. S3 Vectorsで関連チャンクを検索する
4. 検索結果からPromptを構築する
5. Claude Sonnet 4.6へPromptを送信する
6. 生成された回答をユーザーへ返す

/chat が503を返す場合、BedrockだけでなくEmbedding、S3 Vectors、回答生成のどの段階で失敗しているかをCloudWatch Logsから確認する。

4. Embedding生成に失敗する場合

CloudWatch Logsで EmbeddingServiceError およびその原因となるBedrockエラーを確認する。

- Embedding Model IDが正しいこと
- AWS Regionが正しいこと
- ECS Task Roleに bedrock:InvokeModel が許可されていること

- 対象Foundation Modelへアクセス可能であること

Document RAG APIではEmbedding ModelとしてAmazon Titan Text Embeddings V2を利用する。Embedding生成に失敗すると質問Vectorを作成できないため、S3 Vectorsによる検索処理へ進むことができない。

5. Claudeによる回答生成に失敗する場合

S3 Vectorsによる検索が成功しているにもかかわらず回答生成に失敗する場合は、Claude呼び出しを確認する。CloudWatch LogsでBedrockServiceError およびBedrock Runtimeから返されたエラーを確認する。

- ClaudeのModel IDまたはInference Profile ID
- AWS Region
- bedrock:InvokeModel 権限
- Inference Profileの状態
- 対象Foundation Modelが利用可能であること

検索結果が取得できている場合、Embedding生成とS3 Vectors検索は成功しているため、回答生成側へ調査対象を絞ることができる。

6. Inference Profileを利用する場合

Document RAG APIのClaude Sonnet 4.6呼び出しではInference Profileを利用する。Inference Profile IDが正しいこと、およびProfileがACTIVEであることを確認する。

Inference Profileは複数RegionのFoundation Modelへリクエストをルーティングする場合がある。そのためIAM PolicyではInference Profileだけでなく、Profileが利用するFoundation Modelへのアクセスも考慮する。

7. Model IDに問題がある場合

Bedrockで指定するModel IDが誤っている場合、モデル呼び出しに失敗する。アプリケーション設定のModel IDとBedrockで現在利用可能なModel IDが一致していることを確認する。

- Embedding: Amazon Titan Text Embeddings V2
- Answer Generation: Claude Sonnet 4.6

Model IDを変更した場合は、アプリケーション設定だけでなく、必要に応じてIAM PolicyのResourceも確認する。

8. 利用できないモデルを指定している場合

過去に利用できたModel IDであっても現在利用可能とは限らない。ResourceNotFoundなどモデル利用に関連するエラーが発生した場合は、指定したモデルが対象Regionで現在利用可能か確認する。

利用できないモデルを指定している場合は現在利用可能なモデルへ変更する。

1. Model IDが正しい
2. 対象Regionで利用可能
3. IAM Policyが対象モデルを許可している
4. Bedrock Runtimeから正常にレスポンスを取得できる

9. AccessDeniedが発生する場合

Bedrock呼び出しでAccessDeniedが発生した場合は、CloudWatch Logsから拒否されたActionおよびResourceを確認する。主なActionは bedrock:InvokeModel とする。

アプリケーションからBedrockを呼び出す権限はECS Task Roleへ付与する。Task Execution RoleへBedrock呼び出し権限を追加して解決してはならない。IAM Policyの詳細はIAM AccessDenied障害対応Runbookを参照する。

10. 503発生時の切り分け

EmbeddingServiceErrorの場合

Embedding生成処理を調査する。Titan Text Embeddings V2のModel ID、Region、IAM権限を確認する。

VectorStoreServiceErrorの場合

S3 Vectorsの検索処理を調査する。Bedrockの回答生成より前の処理で失敗しているため、Claude側の障害として扱わない。

BedrockServiceErrorの場合

S3 Vectors検索後のClaude回答生成処理を調査する。ClaudeのModel ID、Inference Profile、Region、IAM権限を確認する。

エラー種別を確認せず、503というHTTPステータスだけからBedrock障害と判断してはならない。

11. 復旧確認

1. Embeddingを正常に生成できる
2. S3 Vectors検索を正常に実行できる
3. Claudeから回答を取得できる
4. POST /chat が正常な回答を返す
5. CloudWatch Logsに同じエラーが再発していない

Embedding Modelを変更した場合は、既存Vectorとの互換性についても確認する。

12. エスカレーション

- Model IDが正しいにもかかわらずモデルを利用できない
- Inference Profileが正常にもかかわらず呼び出しに失敗する
- IAM Policy上は許可されているにもかかわらずAccessDeniedが継続する
- 対象Regionでのモデル提供状況を判断できない
- Amazon Bedrockサービス自体の障害が疑われる

エスカレーション時には、発生時刻、使用しているModel ID、Inference Profile ID、AWS Region、CloudWatch Logsのエラー、ECS Task Role、発生している処理がEmbeddingか回答生成か、実施済みの確認および復旧作業を共有する。