

Document RAG API - Amazon S3障害対応Runbook

1. 目的

本Runbookは、Document RAG APIが文書ストレージとして利用するAmazon S3で障害またはデータ不整合が発生した場合の確認および切り分け手順を定める。

対象: PDFアップロード失敗、登録済み文書の取得失敗、文書削除失敗、S3上のPDFとDocument Metadataの不整合、S3とS3 Vectorsの登録状態の不整合、S3アクセス時のAccessDenied。

2. Document RAG APIにおけるS3の役割

Amazon S3を文書データの永続ストレージとして使用し、アップロードされたPDFファイルとDocument Metadataを保存する。Document Metadataにはdocument_id、filename、chunk_countを記録する。

Embeddingおよびチャンク検索用VectorはAmazon S3 Vectorsへ保存する。Amazon S3とAmazon S3 Vectorsは別のストレージとして扱う。

3. 文書登録の基本フロー

1. PDFを受信する
2. document_idを生成する
3. PDFからテキストを抽出する
4. テキストをチャンクへ分割する
5. Embeddingを生成する
6. PDFをAmazon S3へ保存する
7. Document MetadataをAmazon S3へ保存する
8. チャンクとEmbeddingをAmazon S3 Vectorsへ保存する

登録処理の途中で失敗した場合は、S3とS3 Vectorsの登録状態が一致しているか確認する。

4. PDFアップロードに失敗する場合

CloudWatch LogsでS3関連エラーを確認する。対象S3 Bucketの存在、正しいBucket名、ECS Task Roleのs3:PutObject、IAM PolicyのResourceが対象Objectを含むことを確認する。

AccessDeniedの場合はS3設定だけでなくECS Task RoleのIAM Policyも確認する。

5. 登録済み文書を取得できない場合

Document Metadata上では文書が存在するにもかかわらずPDFを取得できない場合は、S3上の対象PDF Object、document_idとObject Keyの対応、s3:GetObject権限、IAM PolicyのResourceを確認する。

Document Metadataのみ存在しPDF Objectが存在しない状態はデータ不整合として扱う。

6. 文書削除に失敗する場合

削除対象はAmazon S3上のPDF、Document Metadata、Amazon S3 Vectors上の対象文書Vector。削除後はdocument_idに紐づくデータが各ストレージに残っていないことを確認する。

S3のDocument Metadataのみ削除し、S3 Vectors上にVectorが残った状態を「孤児Vector」とする。孤児Vectorは全文書横断検索時に検索対象となり、削除済み文書が回答根拠として利用される可能性がある。

7. S3とS3 Vectorsのデータ不整合

全文書横断検索ではS3上のDocument MetadataとS3 Vectors上のVectorが整合している必要がある。Document Metadata上では2文書のみ存在するのに過去文書のVectorが残っていれば不整合と判断する。

S3のdocument_id、各Document Metadataのchunk_count、Vector Key、Vector Metadata内のdocument_id・source・chunk_indexを比較する。各文書のVector数とchunk_countが一致することを確認する。

8. 孤児Vectorが発生した場合

まず削除対象を特定し、現在有効なdocument_idに紐づくVectorは削除しない。不要なVectorのみ削除する。

削除後は、不要Vectorがないこと、有効Vectorが残ること、各文書のVector数とchunk_countが一致すること、Vector Metadataに必要項目が存在することを確認する。

データ不整合を隠す目的で欠落Metadataへデフォルト値を設定して処理を継続してはならない。

9. AccessDeniedが発生する場合

CloudWatch Logsから拒否されたActionとResourceを確認する。主なActionはs3:PutObject、s3:GetObject、s3:DeleteObject、s3:ListBucket。Object操作とBucket操作では対象Resourceが異なる。IAM Policyの詳細はIAM AccessDenied障害対応Runbookを参照する。

10. 復旧確認

PDFアップロード、Document Metadata取得、登録済み文書取得、RAG検索、文書削除後の残存データ、S3とS3 Vectorsのdocument_idおよび件数の整合を確認する。

データ不整合修正後は単一文書検索だけでなく全文書横断検索も実行し、削除済み文書が検索結果に含まれないことを確認する。

11. エスカレーション

S3上のデータ欠損、削除対象Vectorを安全に特定できない、不整合原因不明、IAM Policy上は許可されているのにアクセス不可、複数文書で継続的な不整合が発生する場合はクラウド基盤担当者へエスカレーションする。

共有情報: document_id、filename、S3 Objectの状態、Document Metadata、chunk_count、S3 Vectors上のVector数、CloudWatch Logsの関連エラー、実施済み確認・復旧作業。